

Severity

Roland Schäfer

4. April 2024

1 Nomenklatur

Im Folgenden wird μ für den *wahren Mittelwert* verwendet. Der Mittelwert unter der Nullhypothese sei μ_0 . Gemessene Werte werden als μ_n mit n als Index angegeben (bei Mayo auch \bar{x}). Die unter der Auswertung von Severity betrachteten Partikularhypothesen bezeichnen wir hier als μ' . Bei Mayo heißen diese Hypothesen μ_1 .

2 Test

Ein einseitiger Test liefert die frequentistische Wahrscheinlichkeit, das konkrete Ergebnis oder ein extremeres zu finden, wenn die H_0 korrekt ist. Analog zum Artikel anhand eines z-Tests über Mittelwerte: Wir betrachten die H_0 in (1).

$$H_0 : \mu_0 = 0 \tag{1}$$

In Worten: *Der Mittelwert unter der Nullhypothese ist 0*. Für die Illustration nehmen wir einen einseitigen -- hier rechtsseitigen -- Test gemäß (2). In Worten: *Der Mittelwert unter der Nullhypothese ist größer als 0*.

$$H_1 : \mu > 0 \tag{2}$$

Die Varianz sei bekannt ($\sigma = 2$), und wir gehen von einer Stichprobengröße von $n = 100$ aus. Damit ist der Standardfehler gegeben gemäß (3).

$$SE = \frac{\sigma}{\sqrt{n}} = \frac{2}{10} = 0.2 \tag{3}$$

Wir betrachten die drei möglichen Ausgänge des Experiments: $\mu_1 = 0.4$, $\mu_2 = 0.6$ und $\mu_3 = 1.0$. In einem Fisherschen Rahmen können diese Beobachtungen die H_0 zurückweisen, hier zu $sig = 0.025$ (bzw. 2σ). Am Beispiel μ_1 gezeigt in (4) mit \mathcal{N} als kumulativer Verteilungsfunktion der Standardnormalverteilung.

$$P(\mu_1 \geq 0.4; \mu = \mu_0 = 0) = 1 - \mathcal{N}\left(\frac{\mu_1}{SE}\right) = 1 - \mathcal{N}(2) = 0.023 \quad (4)$$

Anders formuliert erreichen wir 2σ , denn (5).

$$\frac{\mu_1}{SE} = \frac{0.4}{0.2} = 2 \quad (5)$$

3 Severity

3.1 Grundidee

Der Test aus Abschnitt 2 verläuft bei einer binären Entscheidung für oder gegen eine Zurückweisung der H_0 in allen drei betrachteten Fällen gleich. Die H_0 wird zurückgewiesen. Der p-Wert gibt zusätzlich darüber Auskunft, wie gut die Evidenz für die Zurückweisung war, denn (6).

$$P(\mu_1 \geq 0.4; \mu = 0) < P(\mu_2 \geq 0.6; \mu = 0) < P(\mu_3 \geq 1.0; \mu = 0) \quad (6)$$

Der Ausgang μ_3 liefert also stärkere Evidenz gegen die H_0 als der Ausgang μ_2 usw. Severity quantifiziert darüberhinaus, **wie gut die Evidenz für konkrete Abweichungen von der H_0** ist. Sie beantwortet also Fragen wie: *Wie gut ist die Evidenz $\mu_1 = 0.4$ für eine Abweichung von $\gamma = 0.2$ von H_0 ?* Die Abweichung γ ist hier eine *Effektstärke* im Sinn von Power-Berechnungen.

Dazu betrachten wir zusätzlich zur $H_1 : \mu > 0$ auf Basis eines konkreten signifikanten Ausgangs eines Experiments weitere Partikularhypothesen H' über den wahren Wert μ wie in (7).

$$\begin{aligned} H' : \mu &> \mu' \\ \mu' &= \mu_0 + \gamma \end{aligned} \quad (7)$$

Der Unterschied zwischen μ und μ_0 ist hier eventuell relevant. Der Test weist die H_0 über einen arbiträr gesetzten Wert μ_0 zurück und sagt im Prinzip damit wenig über μ . Severity quantifiziert die Evidenz für Schätzwerte μ' des wahren Werts μ als Abweichung von μ_0 um die Differenz γ . Diese Betrachtung ist zulässig, sofern der Test bereits gezeigt hat, dass es gute Evidenz dafür gibt, dass die H_0 (in die erwartete Richtung) inkorrekt ist.

3.2 Wann ist Severity niedrig?

Wir setzen als Beispiel $\mu' = 0.2$. Die Severity für μ' soll **niedrig** sein, wenn bei $\mu' = \mu = 0.2$ der konkrete Messwert μ_1 trotzdem sehr häufig (= frequentistisch wahrschein-

lich) ist. Dies ist generell der Fall, wenn die Stichprobe klein oder die Varianz groß ist. Es ist unabhängig davon auch der Fall, wenn die Differenz zwischen μ' und μ_1 größer bzw. positiver wird, wenn wir also eine stärkere Inferenz bezüglich der Punktschätzung des wahren Werts tätigen wollen. Im betrachteten Beispiel ($\mu' = 0.2$) ist $\mu' - \mu_1 = 0.2 - 0.4 = -0.2$. Würden wir hingegen eine Partikularhypothese $\mu' = 0.6$ betrachten, wäre $\mu' - \mu_1 = 0.6 - 0.4 = 0.2$. Bei gleichbleibender Varianz und Stichprobengröße sollte dies auch (wenn $\mu' = \mu = 0.2$) intuitiv unwahrscheinlicher sein, denn eine Beobachtung von 0.4 liefert schlechtere Evidenz für eine Abweichung um 0.6 von 0 als für eine Abweichung von 0.2 von 0. Es wird deutlich, dass die ursprüngliche H_0 und die Richtung der Ausgangshypothese mit Severity zusammenhängen. Bei einem linksseitigen Test sollte Severity hingegen kleiner werden, je kleiner (bzw. je negativer) die Differenz zwischen μ' und μ_1 wird.

3.3 Wann ist Severity hoch?

Die Severity für $\mu' = 0.2$ soll nun **hoch** sein, wenn der Messwert $\mu_1 = 0.4$ selten zu erwarten ist, falls $\mu' = \mu$.

(Wird fortgesetzt.)

3.4 Veranschaulichung und Berechnung

Abbildung 1 zeigt die Situation für $\mu' = 0.2$. Die schwarze Kurve zeigt die Dichte der Standardnormalverteilung für den ursprünglichen Test, der mit $p = 0.023$ die H_0 zurückweisen konnte. Die blaue Schleppe für den Beobachtungswert $\mu_1 = 0.4$ entspricht 2.3% der frequentistisch erwartbaren Werte. Unter der Annahme, dass $\mu = \mu' = 0.2$, zeigt bei den gleichen Parametern σ und n die rote Kurve die erwartete Verteilung der Messwerte um $\mu' = 0.2$. Die grüne Schleppe (ebenfalls für den Beobachtungswert $\mu_1 = 0.4$) entspricht dem Anteil der erwarteten Messwerte, die dann größer oder gleich 0.4 sind. Da $SE = 0.2$ und $\mu_1 - \mu' = 0.2$, entspricht dies $1 - \mathcal{N}(1) = 0.16$. In diesem Fall wären also $\mathcal{N}(1) = 0.84$ (84%) der Werte kleiner als 0.4, also (8). Die Klausel *is true* nach dem Semikolon wurde als redundant ausgelassen.

$$SEV(\mu > 0.2) = P(\bar{X} < 0.4; \mu \leq 0.2) \quad (8)$$

Berechnet wird hier die *minimale* Severity. Abbildung 2 zeigt dasselbe für $\mu' = 0.1$. Trivialerweise $\mu_1 - \mu' = 0.4 - 0.1 = 0.3$. Bei $SE = 0.2$ entspricht die Fläche unter der Kurve minus der grünen Schleppe einem Anteil von $\mathcal{N}(1.5) = 0.93$. Kleinere δ entsprechen größeren Wahrscheinlichkeiten, also einer größeren Severity.




Abbildung 1: Severity for H' : $\mu' > 0.2$ bei der Beobachtung $\mu_1 = 0.4$




Abbildung 2: Severity for H' : $\mu' > 0.1$ bei der Beobachtung $\mu_1 = 0.4$

Paralleles gilt für größere beobachtete Abweichungen von 0 wie in Abbildung 3 mit $\mu_1 = 0.6$ und $\mu' = 0.2$. Hier gilt $\mathcal{N}(2) = 0.98$ wegen $\mu_1 - \mu' = 0.6 - 0.2 = 0.4$ bei $SE = 0.2$. Steigt der Beobachtungswert μ_1 oder sinkt der Schätzwert μ' , dessen Severity zu bewerten ist, wird die Severity größer. Daher stellt die Berechnung mit (9) allgemein eine Untergrenze für SEV dar.

$$SEV(\mu > \mu') = P(\bar{X} < \mu_1; \mu < \mu') = \mathcal{N}\left(\frac{\mu_1 - \mu'}{SE}\right) \quad (9)$$




Abbildung 3: Severity for H' : $\mu' > 0.2$ bei der Beobachtung $\mu_1 = 0.6$

Für drei Beobachtungen ($\mu_1 = 0.4$, $\mu_2 = 0.6$, $\mu_3 = 1.0$) zeigt Abbildung 4 die Severity-Kurven für $\delta \in [0, 1]$.

4 Zweiseitige Tests




Abbildung 4: Severity-Kurven für verschiedene Beobachtungen